

# Laporan Proyek Klasifikasi Gambar: Deteksi Penggunaan Masker Menggunakan Transfer Learning dengan ResNet18

Disusun oleh:

Rizky Cahyono Putra

442023611012

Teknik Informatika

Universitas Darussalam Gontor

14 Juni 2025

## BAB 1: PENDAHULUAN

### 1.1 Latar Belakang

Klasifikasi gambar merupakan salah satu tugas fundamental dalam bidang visi komputer (*computer vision*) dengan aplikasi yang luas, mulai dari kendaraan otonom hingga diagnosa medis. Dalam konteks kesehatan masyarakat, kemampuan untuk memonitor kepatuhan penggunaan alat pelindung diri seperti masker menjadi relevan. Membangun model *deep learning* untuk tugas ini dari nol membutuhkan sumber daya komputasi dan dataset yang sangat besar.

*Transfer learning* hadir sebagai solusi yang efisien. Teknik ini memungkinkan kita untuk memanfaatkan model yang telah dilatih pada dataset berskala besar (seperti ImageNet) dan mengadaptasinya untuk tugas spesifik dengan dataset yang lebih kecil. Pendekatan ini secara signifikan mengurangi waktu pelatihan dan kebutuhan data, sekaligus seringkali menghasilkan performa yang sangat baik.

### 1.2 Rumusan Masalah

Bagaimana cara membangun sebuah model klasifikasi yang akurat dan efisien untuk membedakan antara gambar orang yang memakai masker dan yang tidak memakai masker menggunakan metode *transfer learning*?

### 1.3 Tujuan Proyek

Tujuan dari proyek ini adalah:

1. Mengimplementasikan alur kerja proyek *machine learning* mulai dari akuisisi data hingga evaluasi model.

2. Membangun model klasifikasi gambar dengan mengadaptasi arsitektur **ResNet18** yang sudah ada.
3. Melatih dan mengevaluasi performa model dalam mengklasifikasikan gambar penggunaan masker pada dataset yang telah disiapkan.

## BAB 2: DATASET

### 2.1 Deskripsi Dataset

Dataset yang digunakan dalam proyek ini berasal dari "Face Mask ~12K Images Dataset" yang tersedia di platform Kaggle. Dataset ini berisi ribuan gambar yang terbagi ke dalam dua kelas:

1. **with\_mask**: Gambar individu yang sedang mengenakan masker wajah.
2. **without\_mask**: Gambar individu yang tidak mengenakan masker wajah.

### 2.2 Akuisisi dan Preparasi Data

Sesuai dengan instruksi tugas, diperlukan dataset dengan total 200 gambar. Karena dataset asli memiliki jumlah gambar yang jauh lebih besar, dilakukan proses kurasi dan preparasi data sebagai berikut:

1. **Pengambilan Sampel Acak**: Sebuah script Python dibuat untuk memilih **100 gambar secara acak** dari folder **with\_mask** dan **100 gambar secara acak** dari folder **without\_mask**. Pengambilan sampel secara acak sangat penting untuk memastikan data yang terpilih memiliki variasi yang representatif dan tidak bias.
2. **Struktur Direktori Akhir**: Sampel data yang terpilih (total 200 gambar) disimpan dalam struktur direktori baru yang siap digunakan untuk pelatihan. Path direktori yang digunakan dalam proyek ini adalah **/kaggle/input/mask-dataset/data-mask/**.
3. **Pembagian Data**: Dataset 200 gambar ini kemudian dibagi lagi secara programatik menjadi 80% data latih (*training set*) dan 20% data validasi (*validation set*). Hal ini memastikan model dievaluasi pada data yang belum pernah dilihat sebelumnya selama proses pelatihan.

## Halaman 3: Metodologi

## BAB 3: METODOLOGI PENELITIAN

### 3.1 Lingkungan Pengembangan

Proyek ini dikembangkan menggunakan bahasa pemrograman Python 3 dengan bantuan beberapa library utama:

- **PyTorch**: Framework *deep learning* utama untuk membangun, melatih, dan mengevaluasi model.
- **Torchvision**: Menyediakan arsitektur model praterlatih (ResNet18) dan utilitas transformasi gambar.

- **Scikit-learn:** Digunakan untuk membuat dan memvisualisasikan *confusion matrix*.
- **Matplotlib:** Digunakan untuk memvisualisasikan grafik akurasi, loss, dan hasil prediksi.
- **Kaggle Notebooks:** Sebagai lingkungan eksekusi kode berbasis cloud dengan dukungan GPU.

### 3.2 Arsitektur Model (Transfer Learning)

Model yang digunakan adalah **ResNet18**, sebuah arsitektur *Convolutional Neural Network* (CNN) yang telah memenangkan kompetisi ImageNet. Proses adaptasi model dilakukan melalui *fine-tuning* dengan langkah-langkah berikut:

1. **Memuat Model Praterlatih:** Model ResNet18 dimuat beserta bobotnya yang telah dilatih pada dataset ImageNet. Bobot ini berisi pengetahuan visual tingkat rendah hingga tinggi yang sangat berguna.
2. **Membekukan Layer Konvolusi (*Freezing Layers*):** Seluruh parameter pada layer-layer konvolusi (bagian ekstraktor fitur) "dibekukan" dengan mengatur atribut `requires_grad = False`. Ini bertujuan agar bobot yang sudah baik dari ImageNet tidak berubah selama pelatihan, sehingga model hanya perlu belajar tugas baru.
3. **Mengganti *Classifier Head*:** Layer terakhir dari ResNet18, yaitu *fully connected layer* (`model.fc`) yang aslinya memiliki 1000 output (untuk 1000 kelas ImageNet), diganti dengan `torch.nn.Linear` baru yang memiliki **2 output**, sesuai dengan jumlah kelas pada dataset kita (`with_mask` dan `without_mask`). Hanya parameter dari layer baru inilah yang akan dilatih.

### 3.3 Proses Pelatihan

Proses pelatihan diatur dengan konfigurasi sebagai berikut:

- **Fungsi Loss:** Menggunakan `CrossEntropyLoss`, yang sangat cocok untuk tugas klasifikasi multikelas.
- **Optimizer:** Menggunakan `Adam Optimizer` dengan *learning rate* sebesar **0.001**. Optimizer ini bertugas memperbarui bobot pada layer *classifier* baru berdasarkan nilai loss.
- **Epoch dan Batch Size:** Model dilatih selama **10 epoch** dengan **batch size 16**.
- **Penyimpanan Model Terbaik:** Selama pelatihan, performa model pada data validasi terus dipantau. Bobot model dengan akurasi validasi tertinggi akan disimpan untuk digunakan pada tahap evaluasi dan prediksi akhir.


## Halaman 4: Hasil dan Evaluasi

### BAB 4: HASIL DAN EVALUASI

#### 4.1 Hasil Proses Pelatihan

Model dilatih selama 10 epoch pada data latih dan dievaluasi pada data validasi di setiap akhir epoch. Riwayat akurasi dan loss selama pelatihan divisualisasikan pada Gambar 4.1.

<br>



Gambar 1: Grafik Akurasi (kiri) dan Loss (kanan) Selama Pelatihan

<br>


Dari grafik di atas, dapat diamati bahwa:

- **Akurasi:** Kurva akurasi *training* dan *validation* sama-sama menunjukkan tren meningkat dan konvergen di nilai yang tinggi. Hal ini menandakan model berhasil belajar dengan baik.
- **Loss:** Kurva loss *training* dan *validation* konsisten menurun, menunjukkan bahwa model semakin baik dalam meminimalkan kesalahan prediksi.
- **Overfitting:** Tidak terdapat celah (gap) yang signifikan antara kurva *training* dan *validation*, yang menjadi indikasi kuat bahwa model tidak mengalami *overfitting* dan dapat menggeneralisasi dengan baik pada data baru.

#### 4.2 Evaluasi Kinerja Model

Evaluasi kuantitatif dilakukan pada data validasi (40 gambar) menggunakan model terbaik yang telah disimpan. Akurasi puncak yang berhasil dicapai pada data validasi adalah **97.5%**.

Untuk analisis kesalahan yang lebih mendalam, *confusion matrix* dibuat seperti yang ditunjukkan pada Gambar



Fungsi-fungsi untuk memvisualisasikan hasil training (grafik loss & akurasi, confusion matrix).

Gambar 1.1: Confusion Matrix pada Data Validasi

**Interpretasi Confusion Matrix:**

- **True Positive (Memakai Masker):** Dari 20 gambar orang memakai masker, model berhasil memprediksi **20** di antaranya dengan benar.
- **True Negative (Tanpa Masker):** Dari 20 gambar orang tanpa masker, model berhasil memprediksi **19** di antaranya dengan benar.
- **False Positive:** Model salah memprediksi **1** gambar orang tanpa masker sebagai orang yang memakai masker.
- **False Negative:** Model tidak membuat kesalahan dalam kategori ini (**0**).

Hasil ini menunjukkan bahwa model memiliki performa yang sangat tinggi dan dapat diandalkan untuk membedakan kedua kelas secara akurat.

## BAB 5: KESIMPULAN DAN SARAN

### 5.1 Kesimpulan

Proyek ini berhasil membangun sebuah model klasifikasi gambar untuk deteksi penggunaan masker dengan performa sangat tinggi. Dengan mengadopsi metode *transfer learning* pada arsitektur ResNet18, model mampu mencapai **akurasi validasi 97.5%** pada dataset yang terdiri dari 200 gambar. Hasil ini membuktikan bahwa *transfer learning* adalah pendekatan yang solid untuk mengembangkan model visi komputer yang akurat dengan sumber daya terbatas.

### 5.2 Saran Pengembangan

Untuk pengembangan di masa depan, beberapa hal dapat dieksplorasi:

1. **Data Augmentation:** Menerapkan teknik augmentasi data (seperti rotasi, flip, atau perubahan kecerahan) pada data latih untuk meningkatkan kemampuan generalisasi model.
2. **Eksplorasi Model Lain:** Mencoba arsitektur praterlatih lain seperti **MobileNetV2** yang lebih ringan dan membandingkan performa serta kecepatan inferensinya.
3. **Fine-tuning Lebih Lanjut:** Setelah melatih *classifier head*, dapat dicoba untuk "mencairkan" (*unfreeze*) beberapa layer terakhir dari bagian konvolusi dan melatihnya dengan *learning rate* yang sangat kecil untuk penyesuaian yang lebih halus.